

## 설명가능한 인공지능 활용 서울시 지하철 혼잡도 예측과 정책적 의사결정 지원을 위한 비즈니스 애널리틱스

박재홍<sup>1)</sup> · 김경원<sup>2)</sup>

<sup>1),2)</sup>국립 인천대학교 글로벌경영대학 무역학부

### 요약

2022년 기준 하루 평균 대중교통 이용 건수 약 1,025만 건 중에서 약 50.3%를 차지할 정도로 서울시민 중 절반 이상이 매일 지하철을 이용한다. 본 연구는 시민들이 승하차하는 과정에서 느낄 수 있는 혼잡도를 실시간으로 빠르고 정확하게 예측 및 설명함으로써 빅데이터 기반 실제 비즈니스의 활용도를 높이는 비즈니스 애널리틱스 방법론을 제시하는 것을 목적으로 한다. 6개 공공데이터베이스를 융합하여 대표적인 머신러닝 및 딥러닝 알고리즘으로 혼잡도를 예측하였고, 설명 가능한 인공지능인 SHAP 알고리즘으로 예측된 혼잡도의 근거를 실시간 효과적으로 제시하였다. Random Forest 알고리즘으로 95% 이상의 미래 혼잡도 예측 성능을 달성하였다. 혼잡도를 낮추기 위해 환승노선을 늘리는 사업이 확충되거나 비점식형태의 승강장 플랫폼을 확충하는 것이 방법일 수 있다. 또한, 출근이 집중되는 월요일과 화요일에 혼잡도가 높아지기 때문에 근무 유연화를 통해 혼잡도의 개선이 가능할 것으로 생각된다.

주요용어: 머신러닝과 딥러닝, 비즈니스 애널리틱스, 설명 가능한 예측, 지하철 혼잡도.

### 1. 서론

대한민국의 수도인 서울의 지하철은 약 600개의 역사에서 매일 약 800만 명이 이용할 만큼 대표적인 교통수단이다. 그리고 2022년 기준 하루 평균 대중교통 이용 건수는 약 1,025만 건인데, 그중에서 약 50.3%를 차지할 정도로 서울시민 중 절반 이상이 매일 지하철을 이용한다 (Transportation, 2023). 또한, 업무 중심 또는 주거 중심 지역들이 많아 인구 밀집도가 높고 출퇴근 시간이나 사회적 정치적 이슈나 이벤트로 인해 특정 시간의 지하철 혼잡도가 증가하여 심각한 문제로 나타나고 있다. 실

1) (22012) 인천광역시 연수구 아카데미로 119, 인천대학교 무역학부, 학부생.

2) 교신저자: (22012) 인천광역시 연수구 아카데미로 119, 인천대학교 무역학부, 부교수.  
E-mail: [thekimk.kr@gmail.com](mailto:thekimk.kr@gmail.com)

제 지하철 혼잡에 따라서 지하철 내 혼잡비용 2,317억 원과 열차 지연으로 인한 혼잡비용 4,960억 원이 발생하고 있다 (김승준, 2016). 향후 수도권 인근 신도시의 개발이나 다양한 형태의 교통수단이 개발될 예정이지만 혼잡도 증가가 해소될 수 있을지 예상하기 어렵고 모든 시간대의 혼잡도를 줄이기는 쉽지 않을 것으로 생각된다. 또한, 최근 전 세계적으로 확산하였던 코로나바이러스 역시 사람들이 밀집되는 폐쇄적 대중교통에서 강한 전염성을 보여 지하철 이용이 많이 감소하였기 때문에, 의학적으로나 서비스적으로 혼잡도 이슈는 다양한 방향으로 확산하기 쉽다.

이러한 사회적 이슈들을 개선하기 위해서는 다수가 이용하는 대표적 교통수단인 지하철의 혼잡도를 사전에 예측하는 것은 서비스의 효율성과 그리고 시민들의 편의성과 안정성 측면에서 중요한 의미가 있다 (Jun과 Il, 2020). 혼잡도를 높은 정확도로 예측할 수 있다면 사전에 지하철 이용 패턴 또는 승객 흐름을 예측할 수 있음을 의미하며, 결과적으로 운행 빈도, 열차 편성, 인력 배치 등 운영 전략을 효과적으로 수립할 수 있다. 그리고 도시 계획이나 지속 가능한 교통 정책 기반 인프라 시스템을 구축하는데, 중요 참고 자료가 될 수 있다. 또한, 높은 혼잡도로 승객들의 이동이 제한 및 응급 상황 대응이 어려워지기 때문에 (Lee et al., 2015) 사전에 예측된 혼잡도를 낮추기 위한 노력은 승객 안전성과 향상과 서비스 수익률과 직결될 수 있다.

본 연구에서는 시민들이 객차 내부든 외부든 혼잡함을 느낄 수 있는 모든 경우를 반영하기 위해 면적 대비 승하차인원을 예측하는 것을 목적으로 한다. 최근엔 머신러닝이나 딥러닝과 같은 인공지능 알고리즘으로 활용하여 혼잡도를 예측하려는 연구가 증가하고 있다. Jeong-Hun과 Hun-Young (2018)은 통계 기반 분위 회귀모형을 사용해서 부산광역시의 기온, 습도, 풍속 등과 같은 기상정보와 대중교통 통행량과 밀접한 관련이 있음을 확인하였다. Jang et al. (2023)는 로지스틱 회귀분석 (Logistic Regression)을 포함하여 의사결정나무 (Decision Tree)와 랜덤 포레스트 (Random Forest) 알고리즘을 사용하여 혼잡도를 예측하였고 정확성 기준 80% 이상의 성능을 달성하였다. 해당 연구는 500m 이내 버스정류장 수, 역세권 건물 수 등 혼잡도 예측에 있어 새로운 지표를 사용했다는 점에서 의의가 있다. Lee et al. (2020)는 대표적인 딥러닝 알고리즘인 다층퍼셉트론 (Multi-layer Perceptron)을 사용하여 혼잡도를 예측하였고, Kim et al. (2024)은 마찬가지로 다층퍼셉트론 알고리즘을 사용하였지만, 공공데이터포털, 기상자료개방 포털, 열린 데이터 광장 등의 공공빅데이터를 활용하여 혼잡도를 예측하였다. 시간대별 특성과 기상 조건을 고려하여 지하철역 혼잡도를 예측한 점에서 의의가 있다.

인공지능의 대표적 알고리즘인 머신러닝과 딥러닝은 높은 성능의 예측값을 제공하지만, 예측 근거를 사람이 이해하기 어렵다는 한계가 있다. 블랙박스 와 같은 이러한 한계를 극복하고자 설명 가능한 인공지능 (Explainable AI, XAI)의 필요성이 높아지고 있다. 설명 가능한 인공지능은 복잡한 인공지능 알고리즘의 결과를 사람이 이해할 수 있도록 설명하는 방법으로 (Adadi과 Berrada, 2018), 사용자는 모델이 어떤 특성과 패턴을 기반으로 결정을 내렸는지 알 수 있어서 신뢰성을 높일 수 있다 (Eun et al., 2021). 본 연구에서는 설명 가능한 인공지능 방법 중 대표적인 SHAP (Shapley Additive explanation) 방법을 이용하여 고성능의 지하철 혼잡도 예측의 근거를 확인하고 변수들의 기여도를 분석한다.

이후의 내용은 데이터를 병합하고 전처리하는 과정, 혼잡도 예측을 위해 사용된 머신러닝과 딥러닝 알고리즘의 소개, 그리고 연구결과와 결론을 제시하며 마무리한다.

## 2. 연구방법

### 2.1 데이터 수집 및 병합

한국은 정보화 시대의 도래와 행정의 투명성 그리고 사회적 활용 효율성을 높이려는 노력으로 공공데이터를 수집하기 시작하였다. 이를 통해 국민의 정보 접근성이 높아졌으며 데이터 기반 정책을 수립하고 민간에서도 창의적인 활용을 할 수 있게 되었다. 본 연구에서는 지하철과 관련된 총 6개의 공공데이터베이스를 융합하여(표 2.1) 지하철 혼잡도의 예측 성능을 개선하였다. 각 데이터베이스의 수집 데이터의 기간은 2015년부터 2024년까지 다양하지만, 공통으로 추출될 수 있는 기간인 2021년부터 2023년까지 추출하였고, 데이터의 단위도 일 단위로 통일하여 통합하였다.

표 2.1 설명가능한 지하철 혼잡도 예측을 위해 융합한 공공데이터베이스 정보

데이터베이스(DB)명	기간	단위	추출변수	종속변수 활용
한국천문연구원_특일 정보	전체	일	연도, 월, 일, 요일, 공휴일, 대체공휴일	-
서울교통공사_1_8호선 역별 일별 시간대별 승객유형별 승하차인원	2015.01-2024.07	일	일별 승하차인원수, 우대권인원수, 청소년인원수	승강장 혼잡도
서울교통공사_지하철 혼 잡도정보	2019-2024	분기	분기별 05시~23시 상하선 혼잡도(정원대비 승차인원)	-
서울교통공사_월별 환승유입인원	2019-2023	연	월별 환승유입인원수	-
서울교통공사_역사운영 현황	2024.06.30. 기준	연	역사운영현황(호선, 역명, 면적, 홍수, 승강장유형, 출입구수, 환승노선)	승강장 혼잡도
서울교통공사_수송순위	2019-2023	연	연도별 수송인원수	상위 10개역 필터링 및 종속변수 결측치 존재여 제외

본 연구에서 “서울교통공사\_1\_8호선 역별 일별 시간대별 승객유형별 승하차인원” 데이터베이스를 기준데이터로 사용하였다. 해당 데이터는 교통카드를 이용한 지하철 호선별 역별(서울시 관할 1~9호선) 시간대별 승하차인원을 나타내는 정보로 수송일자, 호선명, 역명, 승하차구분, 승객유형, 시간대별 승하차인원을 알 수 있다. 여기서 변수를 가공하여 시간대별 승하차인원의 합과 차, 시간대별 우대권인원수, 시간대별 청소년인원수 변수를 추가하였다. “서울교통공사\_지하철혼잡도정보” 데이터베이스를 5시부터 23시까지 시간대별 상선 혼잡도와 하선 혼잡도로 분리하여 위 기준 데이터에 병합하였다. 그 다음으로 "서울교통공사\_월별 환승유입인원" 데이터베이스의 역 및 월별 환승유입인원 변수를 기준 데이터에 병합하였다. 그 후 2024년 6월 30일 기준 "서울교통공사\_역사운영 현황" 데이터베이스에서 역별 면적, 출입구, 섬식여부, 환승노선 갯수를 추출해서 기준 데이터에 병합하였다. 그리고 종속변수로 사용된 승

강장혼잡도를 면적 변수와 승하차인원(합) 변수를 사용하여 생성하였다. 그 외에 역별 및 시간대별, 상행\_평균운행간격, 하행\_평균운행간격, 상행\_운행횟수, 하행\_운행횟수 변수를 생성하였다. 마지막으로 날짜의 경우, 위 데이터에서 수송일자를 활용하여 년도, 월, 일, 요일, 주 변수를 만들었고, 파이썬 holidayskr 라이브러리를 통해 공휴일 변수를 생성할 수 있었다.

생성된 공공빅데이터 기반 융합 데이터베이스에서 종속변수를 예측하기 위해 나머지 23개의 독립변수들을 사용하여 모델링할 때 알고리즘이 이해할 수 있는 형태로 전처리 후 반영해야 한다. 전처리 과정에서 불필요한 변수들을 삭제하기도 하고 문자로 된 응답 값은 별도의 변수나 숫자로 변환하며 최종적으로 정리된 숫자들은 응답 값의 범위를 맞추기 위해 특정 범위로 스케일을 맞춘다. 마지막으로 평균적으로 역마다 약 5.49만개 정도의 샘플들을 8:2의 비율로 구분하여 훈련 (Training) 세트와 테스트 (Test) 세트로 분리하였다. 훈련 세트는 모델링을 위한 학습에 사용되고 모델의 하이퍼파라미터를 결정하기 위해 평균 제곱 오차 (Mean Squared Error, MSE)가 최대가 되는 방향으로 설정하였다. 그리고 테스트 세트는 미래 데이터로 가정하여 학습된 모델이 미래에 얼마나 지하철 혼잡도를 잘 예측하는지 평가하는 데 사용된다. 기본적으로 지하철 혼잡도가 어떤 원인으로 설명되더라도 그 해석이 미래 고객들이 이용할 지하철의 혼잡도를 실제로 잘 예측하는 설명이어야 고객들에게도 관련 의사결정자들에게도 정책적 활용 가치가 높을 것이다.

## 2.2 데이터 전처리 및 변수 추출

본 연구를 위해 각 데이터베이스에서 추출할 수 있는 변수들을 생성하였고 필요에 따라서는 여러 개의 데이터베이스 변수들을 결합하여 생성하기도 하였다. 총 수집된 데이터의 양은 약 55만개의 샘플과 총 24개의 혼잡도 관련 변수가 생성되었다. 그리고 혼잡도가 낮은 경우보다 혼잡도가 높은 경우를 집중적으로 예측이 필요하므로 결측치가 존재하지 않는 경우 중 수송인원수가 많은 상위 10개의 역을 예측 대상으로 선정하였다. 수집된 데이터의 지하철 노선은 1호선부터 8호선까지 중 2호선이 총 7개의 역으로 가장 많이 포함되어 있다. 본 연구의 종속변수인 승강장혼잡도는 “면적 대비 승하차인원”으로 정의된다. 승강장 혼잡도의 평균값은 59.97이며 최소 0.25부터 최대 502.32까지 분포되어 있다. 그리고 승강장혼잡도를 제외한 나머지 23개의 변수가 독립변수로 사용되어 승강장혼잡도를 예측하는 주요 요인들로 활용된다.

## 2.3 머신러닝 및 딥러닝 모델링

본 연구에서는 선형회귀분석 (Linear Regression), 랜덤포레스트 (Random Forest), 엑시지부스트(XGBoost), 라이트지비엠(LightGBM), 캣부스트(CatBoost) 총 5개의 머신러닝 알고리즘과 2개의 대표적인 딥러닝 알고리즘인 다층 퍼셉트론 (Multilayer Perceptron, MLP), 합성곱 신경망(Convolutional Neural Network, CNN)을 사용하여 모델링하였다. 머신러닝은 인공지능의 한 방법론으로 예측 오차를 줄이는 방향으로 설계되었다. 오차는 편향과 분산으로 분리될 수 있는데, 예측의 안정성에 초점을 두어 분산을 줄이기 위해 샘플링 기법을 활용하는 배깅(Bagging)과 성능에 초점을 두어 편향을 줄이기 위해 반복적인 모델링을 활용하는 부스팅(Boosting)으로 구분될 수 있다.

딥러닝도 인공지능의 한 방법론으로, 인간의 두뇌 구조에서 영감을 받아 개발되었

다. 데이터의 복잡한 패턴들을 학습하기 위해 연속된 층 (Layer)을 중첩하여 변수들의 모든 상호작용을 포함하여 의미 있는 규칙들을 학습해 내는 데 강점이 있다. 이러한 구조의 기본이 되는 알고리즘으로 다층 퍼셉트론이 있으며, 이미지나 시계열 등의 데이터도 학습해 낼 수 있도록 층의 구조나 흐름을 개선하여 합성곱 신경망과 순환 신경망 등으로 확장되었다. 특히 CNN은 이미지 분류 특화 알고리즘이지만 내부 구조가 결국 특징을 요약한 것이기 때문에 회귀 문제에도 활용할 수 있다. 특징을 요약하기 위해 합성곱, 풀링, 완전 연결층을 활용하여 인접한 특성값들의 관련성에 더욱 초점을 두어 학습한다. 따라서 다양한 변수들의 상호작용을 포함한 특징들이 학습될 것이고 마지막 출력은 지하철 혼잡도 값이 출력되며 회귀 문제를 해결한다. 알고리즘을 성능을 공평하게 비교하기 위해 가급적 같은 매개 변수값을 사용하였다. (표 2.2).

표 2.2 지하철 혼잡도 모델링에 사용한 알고리즘의 하이퍼파라미터

Algorithm	Parameter	Value
Linear Regression	Intercept	True
	Max Iteration	100
	Random State	0
Random Forest	Samples	100
XGBoost	Criterion	Gini
LightGBM	Minimum Spitting Samples	2
CatBoost	Random State	0
MLP	TensorFlow Random Seed	0
	Number of Hidden Layers	2
	Unit Numbers for Hidden Layers	(100, 100)
	Activation for Hidden Layers	Relu
	Activation for Output Layer	Identity
	Loss	Mean Squared Error
	Optimizer	Adam
	Epochs	500
	TensorFlow Random Seed	0
	Number of Convolution Layers	1
CNN	Unit Numbers for Convolution Layers	64
	Number of Dense Layers	2
	Kernel Size	2
	Stride	1
	Padding	Valid
	Unit Numbers for Dense Layers	64
	Activation for Hidden Layers	Relu
	Activation for Output Layer	Linear
	Loss	Mean Squared Error

Learning Rate	0.001
Optimizer	Adam
Batch Size	32
Epochs	10

### 2.4 설명가능한 인공지능: SHAP

머신러닝과 딥러닝은 발생 가능한 변수들의 모든 상호작용을 스스로 생성하여 학습하기 때문에 인간의 수준을 뛰어넘는 성능 달성을 가능하게 하였다. 하지만 왜 그러한 결과가 발생한 것인지 쉽게 확인하거나 설명하기는 어려운 블랙박스 알고리즘이다. 일부 머신러닝 알고리즘이 변수들의 중요도 (Feature Importance)를 출력하지만, 방향성이 없으므로 해석에 주의를 기울여야 한다. 하지만 SHAP (SHapley Additive exPlanations)는 지역적 해석 가능한 모델 독립 설명 (Local Interpretable Model-agnostic Explanations, LIME)과 셰플리 값 (Shapley Value)을 연결한 이론으로, 이러한 블랙박스와 같은 알고리즘들의 한계를 보완하여 지하철 혼잡도 예측에 영향을 주는 변수들의 특징과 방향을 설명해준다. LIME은 주어진 데이터 값들을 변화시킬 때 모델 예측값의 변화와의 관련성을 가중치로 계산한다 (Molnar 2023). 그리고 셰플리 값은 협력 게임 이론 (Coalitional Game Theory)을 기반으로 변수들의 기여도를 계산하는 지표로 생각할 수 있다. 따라서 변수들이 가질 수 있는 모든 협력 조합의 경우들을 생성한 후 실제 값들이 입력되었을 때 변화된 예측값의 기여도 평균을 계산한다. 하지만 연산량이 매우 많을 수 있으므로 랜덤 샘플링 기법을 활용하여 계산의 효율성을 높인다. 이 2가지 이론이 결합한 SHAP를 사용하여 지하철 혼잡도에 기여하는 변수들의 정도와 방향성을 알 수 있고 블랙박스와 같은 인공지능 알고리즘을 설명 가능케 한다.

### 2.6 성능평가 지표

지하철 혼잡도를 예측하고 설명의 신뢰성을 높이기 위해 6개의 회귀 평가 지표를 사용하여 모델링의 성능을 확인한다. 이들은 RMSE (Root Mean Squared Error), MSPE (Mean Squared Percentage Error), MAE (Mean Absolute Error), MAPE (Mean Absolute Percentage Error), MedAE (Median Absolute Error), MedAPE (Median Absolute Percentage Error)이다. 모든 지표는 예측 성능이 좋을수록 낮은 수치들이 나오도록 실제값과 예측값의 차이로 구성되어 있다. 따라서 6개의 평가 지표 모두 낮은 수치가 나오는 경우 지하철 혼잡도를 잘 예측하는 모델이라 볼 수 있다.

## 3. 연구결과

### 3.1 예측 성능평가

지하철 혼잡도의 미래 예측 성능을 확인하기 위해 머신러닝 및 딥러닝 알고리즘의 성능을 평가한다. 알고리즘에 데이터를 학습시킨 후, 테스트 세트에서의 예측 성능을 평가한다. 각 역마다의 모든 알고리즘의 검증지표 순위를 추정한 후 10개역의 순위 평균치 (표 3.1)와 알고리즘마다 10개역의 검증지표 평균값 (표 3.2)를 통해 더욱

일반화된 알고리즘의 예측력 설명이 가능하다. 표 3.1를 보면 RMSE와 MSPE의 경우 MLP 알고리즘이 10개역 평균 순위가 1.38로 나타난다. 즉, 대부분의 RMSE 지표는 MLP 알고리즘의 지하철 혼잡도 예측 순위가 1등으로 나타남을 의미한다. 그런데 RMSE를 제외한 나머지 4개 검증지표에서는 랜덤 포레스트 알고리즘이 10개역 평균 순위가 1.08와 1.00으로 나타났다. 따라서 나머지 검증지표들에선 랜덤 포레스트 알고리즘이 거의 항상 1등을 했다는 것이다. 따라서 6개의 검증지표 중 4개의 검증지표에서 가장 높은 순위를 차지한 알고리즘은 랜덤 포레스트이다. 그리고 다음 순위를 차지한 알고리즘은 MLP다. 실제 알고리즘별로 10개역의 검증지표 수치를 평균해 보았더니 (표 3.2), 1순위를 차지한 랜덤 포레스트 알고리즘이 평균치 기준인 MSPE에서 5.01%, MAPE에서 5.32%를 차지할 만큼 10% 미만의 오차를 보이며 정확하게 지하철 혼잡도를 예측하는 것으로 나타났다. 2순위를 차지한 MLP도 MSPE와 MAPE가 각각 7.17%와 8.24%를 나타낼 정도로 높은 정확도를 보인다. 반면 전통적인 선형회귀분석 알고리즘은 순위에서도 최하위이며 실제 예측 오류는 MSPE가 217% 만큼 매우 부정확한 예측임을 알 수 있다.

표 3.1 수송인원수 상위 10개 역의 미래 예측 성능 검증지표 순위 평균

Algorithm	RMSE	MSPE	MAE	MAPE	MedAE	MedAPE
Linear Regression	7.00	7.00	7.00	7.00	7.00	7.00
Random Forest	1.92	1.92	<u>1.00</u>	<u>1.08</u>	<u>1.00</u>	<u>1.00</u>
XGBoost	4.54	4.54	4.46	4.46	4.46	4.46
LightGBM	4.52	4.54	4.69	4.62	4.52	4.62
CatBoost	5.92	5.92	5.85	5.92	6.00	5.92
MLP	<u>1.38</u>	<u>1.38</u>	2.54	1.92	2.31	2.08
CNN	2.69	2.69	2.46	3.00	2.69	2.92

표 3.2 알고리즘별 수송인원수 상위 10개 역의 미래 예측 성능 검증지표들 중 퍼센트 오차평균

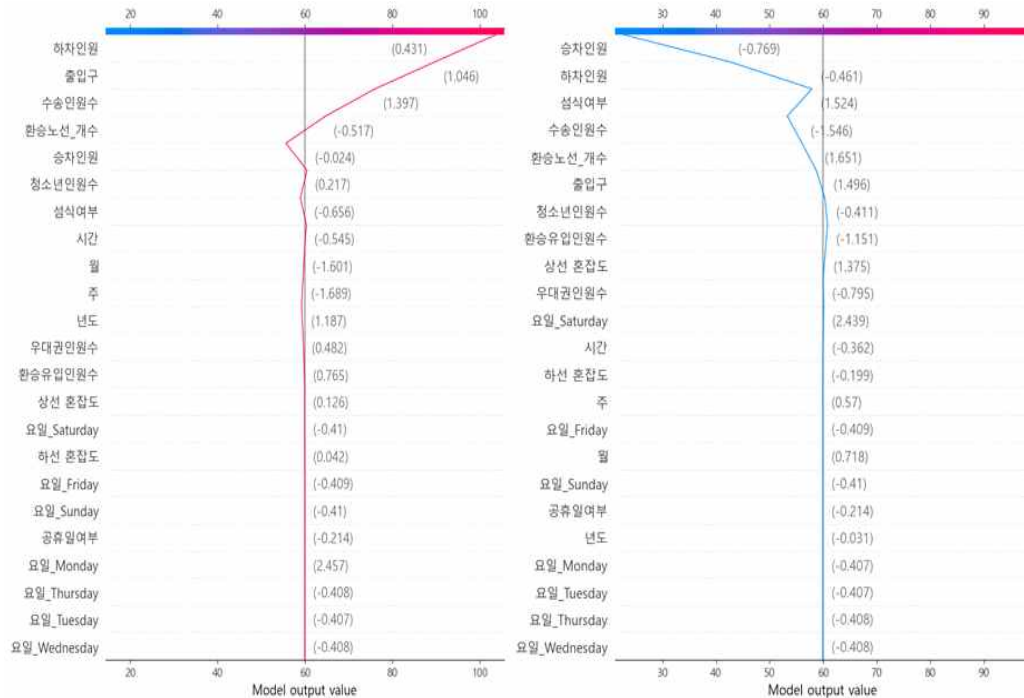
Ranking	MSPE	MAPE	MedAPE
Random Forest	5.01%	5.32%	17.34%
MLP	7.17%	8.24%	59.44%
CNN	8.13%	9.37%	75.27%
XGBoost	9.91%	14.34%	341.08%
LightGBM	10.22%	14.37%	347.00%
CatBoost	13.10%	17.66%	482.05%
Linear Regression	217.66%	53.74%	2872.37%

### 3.2 지하철 혼잡도 예측의 설명력 분석



머신러닝 그리고 딥러닝과 같은 인공지능 알고리즘은 복잡한 비선형 패턴과 변수들의 모든 상호작용 조합까지도 학습을 하여 모델을 만들기 때문에 예측에 기여하는 독립변수들의 기여도를 단순하게 파악하기 어렵다. SHAP를 사용하면 지하철 혼잡도의 높은 미래 예측 성능이 왜 그러한지 독립변수들의 상대적 기여도로 평가할 수 있다. 따라서 높은 예측 성능 뿐만 아니라 독립변수들이 어떠한 방향으로 기여해서 그러한 높은 미래 예측 성능을 달성하였는지 설명해주기 때문에, 실제 지하철 교통 비즈니스에 활용되기도 용이하고 신뢰성도 높아 의사결정에 용이하게 활용될 수 있다. 그리고 이러한 실시간 혼잡도처럼 누적된 혼잡도 예측과 설명력들을 모두 결합하여 일반화된 정책으로 활용할 수 있는 설명력을 시각적으로 표현하기 때문에 이해하기 쉽다.

우선 실시간 지하철 혼잡도에 대한 설명력을 의사결정 플롯 (Decision Plot)으로 시각화할 수 있다. 가장 높은 성능을 보이는 랜덤포레스트 알고리즘을 기준으로, 그림 3.1은 미래 특정일을 임의로 선택하여 미래 강남역 혼잡도를 예측하고 어떻게 측정된 것인지 변수들의 기여도를 내림차순으로 보여준다. 실제 강남역의 혼잡도가 약 105점 정도로 높을 때 하차인원, 출입구, 수송인원수, 환승노선\_개수, 청소년인원수 등은 혼잡도를 높이는 변수들이고 “승차인원, 섬식여부, 년도” 등은 혼잡도를 낮추는 변수들이다. 그 외 나머지 변수들은 혼잡도에 크게 기여하지 못하는 모습이다. 하지만 강남역 혼잡도가 낮을 때 “승차인원, 하차인원, 수송인원수, 환승노선\_개수, 출입구” 등은 오히려 혼잡도를 낮추는 변수로 작용하기도 한다. 그리고 “섬식여부” 도 반대로 혼잡도를 높이는데 기여하고 있다. 미래 특정일과 상황에 따라 변수들이 혼잡도를 높이거나 낮추는데 기여하는 정도나 방향은 얼마든지 달라질 수 있었다. 이러한 과정에서 실시간으로 높은 정확도의 혼잡도를 예측할 뿐만 아니라 어떻게 그러한 수치가 나오게 되는지 의사결정 근거로 활용하기에도 매우 용이하다.



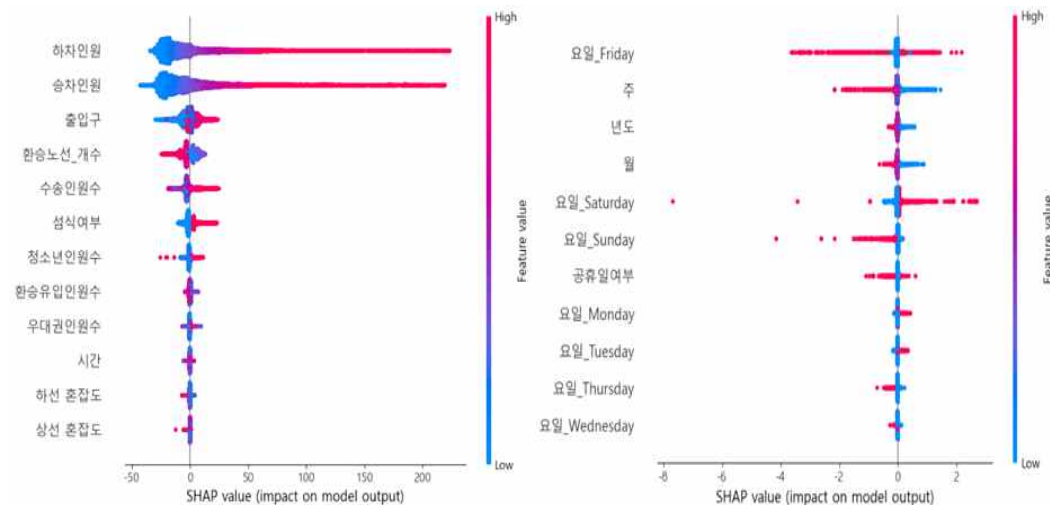
(a) 강남역 혼잡도 높을 때 (b) 강남역 혼잡도 낮을 때  
 그림 3.1 미래 특정일 대상 강남역의 혼잡도 예측과 변수기여 설명력 기반 의사결정

특정일의 지하철 혼잡도에 대한 변수들의 기여를 통해 각 변수가 지하철 혼잡도에 일반화된 기여 방향을 보장하지 않는다. 그러한 이유로 특정 변수가 지하철 혼잡도에 어떠한 방향성을 가지는지 일반화하는 것은 다소 위험할 수 있다. 정책적 근거를 위해 일시적으로 사용할 수는 있겠지만 정책 입안자들 또는 시민들에게 이해될만한 정보로 실시간으로 와닿기 어렵기 때문이다. 하지만 실시간 혼잡도의 예측 설명력을 확인할 수 있었으니 이를 누적하여 표현한다면 충분히 일반화된 인사이트로 재표현 할 수 있을 것이다. 단, 기여 방향을 긍부정과 같은 이분법적인 해석은 매우 조심해야 함을 위의 실시간 예측 결과를 통해 다시 한번 강조한다. 따라서 본 연구에서는 매우 명확한 관계성이 나타나는 변수에 대해서만 조심스럽게 해석을 제안하면서 머신러닝과 딥러닝 기반의 설명 가능한 인공지능의 효과적인 비즈니스 애널리틱스를 안내하는데 집중한다.

각 샘플마다의 지하철 혼잡도 예측 설명력을 누적하여 일반화된 설명력을 확인한 것이다. 그림 3.2는 랜덤 포레스트 알고리즘으로 모든 미래 데이터의 지하철 혼잡도 예측을 위한 특성 영향을 시각화한 것이다. 우선 세로축은 왼쪽과 오른쪽으로 2개가 있다. (왼쪽)세로축은 종속변수에 영향을 주는 변수 중요도를 내림차순으로 정렬한 것이기 때문에 높은 곳에 있는 변수들은 낮은 곳에 있는 변수들보다 지하철 혼잡도 예측에 더욱 많이 기여한다. 즉, “하차인원, 승차인원, 출입구, 환승노선\_개수, 수송인원수” 등의 순서로 예측 성능의 변수 기여도가 분석되었다. 그리고 (오른쪽)세로

측은 변수들의 값이 낮은 경우는 파란색 계열로 그리고 높은 경우는 빨간색 계열로 표시하여 변수들의 값의 변화를 표시하였다. 마지막으로 가로축에 바로 지하철 혼잡도의 예측값을 표시하여 변수의 값의 변화에 따라 낮은 혼잡도(음수)에서 높은 혼잡도(양수)로의 예측값 변화를 이해할 수 있다. 시점마다 변수의 수치는 다양할 수 있고 수치별 지하철 혼잡도 또는 특성 영향 방향도 다양할 수 있으므로, 각 변수의 값과 대응되는 예측값 위치를 모두 누적하여 표현하면 각 변수의 값의 변화에 따른 지하철 혼잡도 기여 방향이 시각화되는 것이다.

“하차인원과 승차인원”은 값이 작을 때(파란색 계열) 혼잡도가 낮게 예측되는 경향이 있고 값이 커지면(빨간색 계열) 혼잡도가 높게 예측되는 경향이 있다. 따라서 해당 변수의 값이 커지면 지하철 혼잡도가 높아진다고 해석할 수 있다. 반대로 “환승노선\_개수”는 값이 커질수록 지하철 혼잡도를 낮춘다고 해석할 수 있다. 이를 정리하여 미래에 지하철 혼잡도를 높일 것으로 예측되는 가장 중요한 변수는 “하차 인원, 승차 인원, 출입구, 섬식여부, 월요일, 화요일” 등이며, 혼잡도를 낮출 것으로 예측되는 변수는 “환승노선\_개수, 환승유입인원수, 하선/상선 혼잡도, 주, 년도, 월, 일요일, 목요일, 수요일” 등으로 해석할 수 있다. 단순히 지하철 관련 변수들뿐만 아니라 시간 정보에 따른 혼잡도 기여도 확인할 수 있다.



(a) 우선순위 1-12위

(b) 우선순위 13-23위

그림 3.2 지하철 혼잡도 예측에 대한 변수들의 기여 설명력 기반 의사결정

## 4. 결론

최근 전 세계적으로 확산하였던 코로나바이러스 역시 사람들이 밀집되는 폐쇄적 대중교통에서 강한 전염성을 보여 지하철 이용이 크게 감소하였기 때문에, 의학적으로나 서비스적으로 혼잡도 이슈는 다양한 방향으로 확산하기 쉽다. 사회적 이슈들을 개

선하기 위해서는 다수가 이용하는 대표적 교통수단인 지하철의 혼잡도를 사전에 예측하는 것은 서비스의 효율성과 그리고 시민들의 편의성과 안정성 측면에서 중요한 의미가 있다.

본 연구는 기존 선행연구와 달리 다음과 같은 5가지 항목에서 기여하고 있다. 첫째, 특정 데이터베이스뿐만 아니라 지하철 관련 공공빅데이터를 모두 융합하여 혼잡도 예측에 활용하였다. 기존 연구들은 적은 수의 공공데이터만을 활용했지만 본 연구는 총 6개의 데이터베이스를 융합하여 공공데이터의 효용을 뒷받침할 수 있었다. 둘째, 기존 연구들이 비즈니스적으로 바로 활용되기엔 낮은 예측 성능이었지만, 본 연구에선 MSPE 기준 95% 이상의 예측 정확성을 보이며 대중교통 관계자들이 실시간으로 바로 활용할 수 있는 방법론을 달성하였다. 이러한 접근은 다양한 시간대와 노선, 그리고 여러 상황에서도 혼잡도를 효과적으로 예측함으로써 효율적인 자원 배분과 운영 계획 수립에 도움 될 수 있다. 셋째, 높은 예측 성능뿐만 아니라 설명가능한 인공지능을 활용하여 예측 결과를 더욱 쉽게 이해할 수 있도록 제시하였다. 설명가능한 인공지능을 통해 예측 결정 과정과 근거를 시각적으로 제공함으로써, 실제 비즈니스와 정책의 의사결정 과정을 보다 투명하고 신뢰할 수 있게 지원한다. 넷째, 클라우드나 고성능 PC 없이도 누구나 현장에서 쉽게 사용할 수 있는 머신러닝 및 딥러닝 기반 비즈니스 애널리틱스 구조를 제시하였다. 누구나 손쉽게 데이터를 학습하고 활용할 수 있도록 설계되었기에 실용성을 극대화하는 연구다.

혼잡도를 낮추기 위해서는 승하차 인원을 줄이는 것이 근본적인 해결책일 수 있지만, 그 외에도 환승노선을 늘리는 사업이 확충되거나 섬식형태가 아닌 승강장 플랫폼을 확장하는 것이 방법일 수 있다. 또한, 한주의 출근이 몰리는 월요일과 화요일에 혼잡도가 높아지기 때문에 근무의 유연화 문화를 통해 혼잡도의 개선이 가능할 것으로 생각된다. 본 연구는 설명 가능한 인공지능을 활용하여 지하철 혼잡도를 실시간으로 빠르게 확인할 수 있는데 도움을 줄 수 있으므로, 서비스 측면에서 시민들에게 빠르고 효과적인 대응책을 마련하는 데 도움이 될 것이다.

## References

- Adadi, A. and Berrada, M. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, **6**, 52138–52160.
- Eun, Y., Bin, S., Yun, J. and Hwan, J. (2021). Study on credit rating model using explainable AI. *Journal of the Korean Data And Information Science Society*, **32**, 283–295.
- Jang, J., Kim, C. and Park, M. (2023). Subway Line 2 Congestion Prediction During Rush Hour Based on Machine Learning. *The journal of Convergence on Culture Technology*, **9**, 145–150.
- Jeong-Hun, L. and Hun-Young, J. (2018). The Impact of Weather Conditions on Transit Ridership Using Quantile Regression Analysis. *Journal of Korea Planning Association*, **53**, 95–106.
- Jun, S. and Il, S. (2020). A Study on Improving Subway Crowding Based on Smart Card Data : a Focus on Early Bird Policy Alternative. *Journal of*

*Information Technology Services*, **19**, 125–138.

Kim, K., Park, S., Choi, S. and Kim, Y. (2024). A Study on Dynamic Analysis and Prediction Modeling of Subway Station Congestion Changes Using Deep Learning Analysis. *Proceedings of Symposium of the Korean Institute of communications and Information Sciences*, **2024**, 1192–1194.

Lee, G., Kim, S., Moon, H., Han, J. and Sangho, C. (2020). A study on Estimating the Transfer Time of Transit Users Using Deep Neural Network Models. *Journal of Korean Society of Intelligent Transport Systems*, **19**, 32–43.

Lee, S. H., 천춘근, Byung-Doo, J., young, B. and 김은지 (2015). Study on Methodology for Effect Evaluation of Information Offering to Rail passengers - Focusing on the Gate Metering Case Study considering congested conditions at a platform -. *Journal of Korean Society of Intelligent Transport Systems*, **14**, 50–62.

Transportation, C. (2023). *Seoul Transportation in 2022*, Seoul Metropolitan Government.

김승준 (2016). *서울시 지하철의 혼잡비용 산정과 정책적 활용방안*, 서울연구원.

## Business analytics to predict Seoul subway congestion and policy decision–making using explainable AI

Jaeheung Park<sup>1)</sup> · Kyungwon Kim<sup>2)</sup>

<sup>1),2)</sup>School of International Trade and Business, Incheon National  
University

### Abstract

More than half of Seoul's residents use the subway every day, accounting for about 50.3% of the approximately 10.25 million average daily public transport trips as of 2022. This study aims to propose a business analytics methodology that improves the usability of big data–based real businesses by quickly and accurately predicting and explaining the congestion level that citizens may feel while getting on and off the subway. Six public databases are merged to predict the congestion level with representative machine learning and deep learning algorithms, and the SHAP algorithm, an explainable artificial intelligence, effectively presents the evidence of the predicted level. The Random Forest algorithm achieved a prediction performance of over 95% for future congestion. To reduce congestion, it may be possible to expand the number of transit routes or expand non–island platforms. In addition, since congestion is higher on Mondays and Tuesdays when commuting is concentrated, it is possible to improve congestion through work flexibility.

**Keywords:** Business analytics, explainable prediction, machine and deep learning, subway congestion.

---

1) Student, School of International Trade and Business, Incheon National University, Incheon 22012, Republic of Korea.

2) Corresponding author: Associate professor, School of International Trade and Business, Incheon National University, Incheon 22012, Republic of Korea. E–mail: thekimk.kr@gmail.com